

# Resolução do Case de Ciência de Dados - Mercado Livre

Lucas Matheus dos Santos Nascimento

## Código e Repositório

Os códigos utilizados neste estudo estão disponíveis em: [https://github.com/nascimentoollucas/Meli\\_Case](https://github.com/nascimentoollucas/Meli_Case)

## 1 Introdução

Este relatório propõe uma solução baseada em Ciência de Dados para prever, com base em informações transacionais, se uma determinada operação é fraudulenta ou não. O desafio está em maximizar o retorno financeiro do Mercado Livre ao aprovar transações legítimas (Classe 0), gera-se lucro de 25% do valor (**Monto**); já ao aprovar uma transação fraudulenta erroneamente (Classe 1) há perda de 100% do valor (Monto).

## 2 Descrição Inicial dos Dados

A base de dados fornecida possui um total de **16.880 registros** e **24 variáveis**, incluindo variáveis artificiais e a variável-alvo **Fraude**. A análise preliminar revelou que:

A Tabela 1 resume os percentuais de valores ausentes encontrados no dataset.

Tabela 1: Percentual de valores ausentes por variável

| Variável         | % Missing |
|------------------|-----------|
| var_C            | 19,0%     |
| var_K            | 76,0%     |
| Demais variáveis | 0,0%      |

## 3 Análise das Variáveis

### 3.1 Distribuição da Variável Alvo

A Tabela 2 apresenta a distribuição percentual das classes da variável **Fraude** na base de dados. Como se observa, há uma predominância de transações legítimas (classe 0), mas a proporção de fraudes (classe 1) é significativa e suficiente para influenciar diretamente as decisões de modelagem.


Tabela 2: Distribuição percentual da variável **Fraude** na base de dados

| Classe | Descrição  | Proporção (%) |
|--------|------------|---------------|
| 0      | Não-Fraude | 72,68         |
| 1      | Fraude     | 27,32         |

### 3.2 Variável var\_K

A variável **var\_K** apresentava valores contínuos no intervalo de 0 a 1. Para evitar possíveis inconsistências em ambientes de produção, especialmente em cenários nos quais operações aritméticas ou comparações com outras variáveis assumem escalas diferentes, optou-se por multiplicar essa variável por 100.

### 3.3 Variáveis var\_A e var\_B




(a) Distribuição de **var\_A** por classe de fraude (b) Distribuição de **var\_B** por classe de fraude

Figura 1: Comparação entre os percentuais de Não-Fraude e Fraude nas variáveis **var\_A** e **var\_B**.

A variável **var\_A** apresentou um comportamento heterogêneo em relação à variável resposta. Valores como 19, 20 e 30 concentram quase exclusivamente transações fraudulentas (acima de 90%), enquanto outros, como 15 e 17, são majoritariamente compostos por transações legítimas. Isso sugere forte poder discriminativo.

Já a variável **var\_B** apresenta uma transição mais gradual: valores baixos estão associados a transações legítimas, e a partir do valor 15 essa tendência se inverte, indicando maior risco de fraude.

### 3.4 Variáveis var\_H e var\_J



(a) Distribuição de **var\_H** por classe de fraude (b) Distribuição de **var\_J** por classe de fraude

Figura 2: Distribuição percentual das variáveis **var\_H** e **var\_J** em relação à ocorrência de fraudes.

A variável **var\_H** apresentou um padrão claro de segmentação: valores superiores a 9 estão fortemente associados a transações fraudulentas, com percentuais próximos de 100%. Por outro lado, os valores

mais baixos possuem proporções variadas, tornando essa variável um bom indicativo de risco com potencial para binarização.

No caso da variável `var_J`, que parece representar códigos de país, há países com predominância quase absoluta de transações legítimas (como `CA`, `CH`, `KR`), enquanto outros, como `ES`, `US` e `UY`, concentram transações fraudulentas. Isso indica que a geolocalização pode ser uma variável altamente preditiva.

### 3.5 Transformação Logarítmica de Variáveis Numéricas

Durante a análise da distribuição das variáveis `var_C` e `var_F`, foi observado um comportamento de crescimento exponencial nos valores superiores, conforme ilustrado na Figura 3. Para investigar esse comportamento, foram calculados os decis e quantis superiores dessas variáveis.




Figura 3: Distribuição exponencial nas caudas superiores das variáveis `var_C` e `var_F`.

Conforme se observa nos gráficos acima, ambas as variáveis apresentam um **crescimento acelerado a partir do 90º percentil**, com valores que sobem rapidamente de forma não linear. Esse tipo de comportamento pode causar impacto desproporcional no ajuste de modelos sensíveis à escala, gerar viés na importância atribuída às variáveis, reduzir a estabilidade estatística dos modelos e aumentar a variância das estimativas nas regiões de cauda. Para mitigar esses efeitos, foi aplicada a transformação logarítmica `np.log1p`, que é utilizada em situações nas quais os valores incluem zero e apresentam assimetria positiva.

Para mitigar esses efeitos, foi aplicada a transformação logarítmica `np.log1p`, que é utilizada em casos onde os valores incluem zero e possuem assimetria positiva.

### 3.6 Tratamento de Formatos e Discretizações

Durante o pré-processamento, identificou-se que as variáveis `var_Q`, `var_R` e `var_S` continham, em sua maioria, valores numéricos em formato `string`, mas apresentavam também alguns registros em formato `datetime` — 17, 3 e 1305 ocorrências, respectivamente. Esses valores foram tratados como ausentes (`NaN`), mantendo os demais dados válidos. O mesmo ocorreu com a variável `Monto`, que apresentava 467 registros em formato de data. Como a taxa de fraude nesses casos era próxima à da base completa (24,2% contra 27,3%), decidiu-se retirar a variável do `dataset`, mas ela foi avaliada no modelo final posteriormente.

A variável `var_J`, possivelmente associada a países, foi discretizada com base na taxa de fraude observada, originando a variável `pais_agg`, que agrupou os países segundo seu risco relativo. Para

essa nova variável categórica, aplicou-se *One-Hot Encoding*, permitindo sua utilização direta nos modelos supervisionados. A Figura 4 apresenta a distribuição das categorias em relação à variável alvo.




Figura 4: Distribuição percentual de fraude por categoria de país após discretização da variável `var_J`.

## 4 Divisão da Base e Seleção de Variáveis

Antes da modelagem, a base foi dividida em três subconjuntos: treino (60%), validação (20%) e teste (20%), garantindo a estratificação por classe da variável **Fraude**. Valores ausentes em variáveis numéricas foram preenchidos com um valor arbitrário (`-999999999`, fora do domínio da variável), de modo a evitar erros em algoritmos que não lidam nativamente com `NaN`, como é o caso da *Random Forest*.

Para a seleção de atributos, foi treinado um modelo de *Random Forest* com 100 estimadores sobre o conjunto de treino, e a importância de cada variável foi calculada com base na métrica *Feature Importance Weight*. As variáveis com importância maior ou igual a 1% foram mantidas para as etapas seguintes. A Tabela 3 apresenta a lista final de variáveis selecionadas.

Tabela 3: Variáveis selecionadas com importância  $\geq 1\%$

|                                |                          |
|--------------------------------|--------------------------|
| <code>var_S</code>             | <code>Monto</code>       |
| <code>var_C_log</code>         | <code>var_B</code>       |
| <code>pais_agg_ES_US_UY</code> | <code>var_K_100</code>   |
| <code>var_P</code>             | <code>var_M</code>       |
| <code>var_L</code>             | <code>var_A</code>       |
| <code>var_E</code>             | <code>pais_agg_MX</code> |
| <code>var_F_log</code>         | <code>pais_agg_AR</code> |
| <code>pais_agg_BR</code>       | <code>var_Q</code>       |
| <code>var_D</code>             |                          |

## 5 Otimização de Hiperparâmetros

Para melhorar o desempenho do modelo, foi utilizado o algoritmo **Tree-structured Parzen Estimator (TPE)** da biblioteca **Hyperopt**, com o objetivo de maximizar a métrica **AUC** no conjunto de teste. A função objetivo foi definida para retornar o valor negativo da AUC, de modo que a otimização minimizasse essa função. A busca foi conduzida em 50 iterações, explorando um espaço de parâmetros que incluiu profundidade da árvore, taxa de aprendizado, número de estimadores, regularizações L1 e L2, **gamma**, **subsample**, **colsample\_bytree** e **min\_child\_weight**. A Tabela 4 apresenta os melhores hiperparâmetros encontrados, os quais resultaram em um valor ótimo de AUC de aproximadamente **0.8339**.

Tabela 4: Melhores hiperparâmetros encontrados com Hyperopt

| Parâmetro        | Valor   |
|------------------|---------|
| max_depth        | 9       |
| learning_rate    | 0.04796 |
| n_estimators     | 290     |
| gamma            | 1.0416  |
| min_child_weight | 9       |
| subsample        | 0.8285  |
| colsample_bytree | 0.9537  |
| reg_alpha        | 3.8552  |
| reg_lambda       | 0.6685  |

## 6 Avaliação do Modelo

O modelo treinado foi avaliado nos conjuntos de validação e teste utilizando como principal métrica a **Área sob a Curva ROC (AUC)**. Ambos os conjuntos apresentaram valor de AUC igual a **0,83**, indicando boa capacidade de separação entre Fraude e Não-Fraude. A Figura 5 mostra as curvas ROC dos dois conjuntos.




Figura 5: Curva ROC nos conjuntos de validação e teste (AUC = 0,83)

Além da performance geral, foi realizada a análise de interpretabilidade do modelo utilizando **valores de SHAP (SHapley Additive exPlanations)**. O gráfico da Figura 6 mostra a contribuição de cada variável para o resultado da predição. Variáveis como **var\_B**, **pais\_agg\_ES\_US\_UY**, **var\_S** e **var\_C\_log** destacaram-se como as mais impactantes na decisão do modelo, reforçando o resultado obtido anteriormente na etapa de seleção de atributos.




Figura 6: Gráfico de valores SHAP para as variáveis selecionadas

## 6.1 Otimização de Threshold com Base no Lucro e no F1-Score

O modelo foi avaliado não apenas por métricas técnicas, mas também pelo retorno financeiro potencial. Considerou-se que, para cada transação legítima aprovada, a empresa ganha 25% do valor da transação, enquanto a aprovação de uma fraude resulta em perda de 100%.

A Figura 7 mostra o comportamento do lucro real em função do threshold de decisão. O melhor desempenho financeiro foi alcançado com threshold igual a **0,19**, resultando em um **lucro máximo de \$ 51.644,56**.




Figura 7: Lucro real em função do threshold de decisão.




Figura 8: F1-score em função do threshold.

A Figura 8 apresenta o comportamento do F1-score conforme o threshold varia. O valor máximo de F1-score foi atingido com threshold em torno de **0,33**, ponto tradicionalmente escolhido em contextos de desbalanceamento de classes.

Contudo, ao utilizar esse threshold para maximizar o F1-score, o lucro resultante foi de \$ **38.783,80**, o que representa uma redução de aproximadamente **25%** em relação ao lucro máximo possível.

Levando em conta o ponto de corte que maximiza o F1-Score, a matriz de confusão no conjunto de validação pode ser analisada na Figura 9.




Figura 9: Matriz de confusão no conjunto de validação

A Tabela 5 apresenta as métricas de avaliação detalhadas.

Tabela 5: Métricas de avaliação por classe no Conj. de Validação

| Classe     | Precisão | Recall | F1-Score |
|------------|----------|--------|----------|
| Não Fraude | 0,87     | 0,83   | 0,85     |
| Fraude     | 0,60     | 0,66   | 0,63     |

## 7 Implantação e Monitoramento

Para avaliar a estabilidade do modelo ao longo do tempo e entre diferentes amostras, foi calculado o **Population Stability Index (PSI)** para as variáveis selecionadas. Esse monitoramento deve ser realizado após a implantação do modelo com frequência diária/semanal.

A Tabela 6 mostra os valores de PSI para cada variável nos conjuntos de teste e validação em relação ao conjunto de treino do modelo. Todos os valores encontrados ficaram abaixo do limite comumente aceito de 0,10, indicando que as variáveis mantêm uma distribuição estável.

Tabela 6: PSI das variáveis selecionadas para os conjuntos de Teste e Validação

| Variável          | Teste  | Validação |
|-------------------|--------|-----------|
| var_L             | 0.0234 | 0.0048    |
| pais_agg_BR       | 0.0110 | 0.0005    |
| var_F_log         | 0.0075 | 0.0171    |
| pais_agg_AR       | 0.0067 | 0.0015    |
| pais_agg_ES_US_UY | 0.0063 | 0.0000    |
| var_E             | 0.0041 | 0.0015    |
| var_M             | 0.0034 | 0.0071    |
| var_B             | 0.0024 | 0.0026    |
| var_A             | 0.0022 | 0.0052    |
| var_C_log         | 0.0020 | 0.0023    |
| var_P             | 0.0017 | 0.0016    |
| var_K_100         | 0.0012 | 0.0012    |
| var_D             | 0.0006 | 0.0005    |
| pais_agg_MX       | 0.0004 | 0.0004    |
| var_S             | 0.0002 | 0.0007    |
| Monto             | 0.0000 | 0.0000    |
| var_Q             | 0.0000 | 0.0000    |

Para avaliar a capacidade discriminativa do modelo, foi realizada uma análise de decil com base no score. As transações foram divididas em 10 grupos (decis), ordenados do score mais alto (decil 10) ao mais baixo (decil 1). A Tabela 7 resume os principais indicadores por grupo, incluindo taxa de detecção (*Detection Rate*), taxa de acerto entre alertas emitidos (*Hit Rate*) e cobertura (*Alert Rate*).



Tabela 7: Indicadores de performance por decil de score

| Decil | Score Mínimo | Score Máximo | Transações | Fraudes | Hit Rate | Detection Rate |
|-------|--------------|--------------|------------|---------|----------|----------------|
| 10    | 653          | 994          | 329        | 279     | 0.8480   | 0.3103         |
| 9     | 462          | 653          | 328        | 186     | 0.5671   | 0.2069         |
| 8     | 332          | 462          | 328        | 128     | 0.3902   | 0.1424         |
| 7     | 238          | 332          | 328        | 104     | 0.3171   | 0.1157         |
| 6     | 173          | 237          | 328        | 75      | 0.2287   | 0.0834         |
| 5     | 122          | 173          | 329        | 32      | 0.0973   | 0.0356         |
| 4     | 83           | 122          | 328        | 46      | 0.1402   | 0.0512         |
| 3     | 56           | 83           | 328        | 25      | 0.0762   | 0.0278         |
| 2     | 30           | 56           | 328        | 15      | 0.0457   | 0.0167         |
| 1     | 1            | 30           | 329        | 9       | 0.0274   | 0.0100         |

Os resultados demonstram que o modelo possui alto poder discriminativo. Cerca de **31% de todas as fraudes** estão concentradas apenas no **decil superior** (score mais alto), enquanto os três primeiros decis (10 a 8) juntos capturam aproximadamente **66% das fraudes** — com um *Hit Rate* superior a 0,84 no decil 10. Essa concentração reforça a aplicabilidade do modelo para estratégias de priorização de análise e monitoramento, permitindo que a equipe de prevenção de fraudes foque esforços em um pequeno grupo de transações com alta probabilidade de risco.

## 8 Considerações Finais

A validação do modelo com **XGBoost** apresentou resultados sólidos, com AUC de **0,84** e F1-score de **0,63**. Como baseline comparativo, foi implementado um pipeline semelhante utilizando **Regressão Logística**, cujos resultados foram inferiores — AUC de **0,79** e F1-score de **0,58**. Ambos os pipelines estão disponíveis no repositório do projeto no GitHub.

Além disso, foi identificada uma anomalia em 467 registros com valor de *Monto* com formato *datetime*, possivelmente causados por erro operacional ou falha de coleta. Foi realizado um teste utilizando os dados no conjunto de Treino, mas excluindo as amostras do conjunto de Teste e Validação, pois impossibilitava a análise de Lucro. De acordo com os resultados obtidos, não obtive diferença significativa nos resultados e os 467 registros foram desconsiderados. Posteriormente, o conjunto de registros excluídos foi analisado separadamente. O desempenho do modelo nesse subconjunto foi coerente com os resultados gerais, indicando robustez e consistência nas predições mesmo em casos atípicos. Eles foram considerados como *NaN* neste caso.